

模型行為異常偵測與修復

模型行為異常偵測，給定一個不知道訓練歷史的模型，我們能不能診斷它是否已經學到異常的 reward-seeking / reward-hacking tendency；若偵測到，能不能在不破壞正常能力的情況下把這個 tendency 移除？

Can We Repair a Reward-Hacked Language Model?

<https://alignment.anthropic.com/2026/reward-seeker/>

現成的 reward-hacked 模型

<https://arxiv.org/abs/2508.17511>

用 SFT 在無害任務上教會模型 reward hacking, 模型與資料集都公開 (Qwen、Llama 等 base 都有), 而且驗證過會 generalize 到沒看過的作弊情境

<https://arxiv.org/abs/2502.17424>

可使用公開 checkpoint (嚴格來說算是廣義行為異常而非 reward hacking)

行為評測環境

把現成模型丟進可作弊的環境收軌跡

<https://arxiv.org/abs/2503.11926>

文獻閱讀工具

<https://www.alphaxiv.org/>